### Atrasos em filtros de Kalman

Gustavo T. Pfeiffer


19/8/2025

## Agenda

- 1. Filtro de Kalman: O que é, para que serve
- 2. Modelo matemático
- 3. Problema dos atrasos
- 4. Solução

## O que é um filtro de Kalman


Sistema X(t) evolui estocasticamente no tempo



- Medidas Y(t) com erros aleatórios
- Objetivo: Estimar X(t) dadas todas as medições Y(0), ..., Y(t) em tempo real

## Exemplo


#### Movimento browniano



# Aplicações

- Tracking de objetos com câmera, LiDAR, etc.
- Posicionamento (GPS, acelerômetro, etc.)
- Sistemas complexos (ex.: reservatórios de petróleo)

## Hipóteses



- Hipóteses
  - Erros de medição são independentes entre si
  - Todas as variáveis são gaussianas (normais multivariadas)
  - Relações entre as variáveis são lineares
- Modelos não-lineares são muito usados na prática, porém são aproximações



Evolução no tempo

• 
$$X(t + \Delta t) = TX(t) + \mathcal{N}(0, A)$$

- Observações
  - $Y(t) = PX(t) + \mathcal{N}(0, B)$

- Evolução no tempo
  - $X(t + \Delta t) = TX(t) + \mathcal{N}(0, A)$
- Observações
  - $Y(t) = PX(t) + \mathcal{N}(0, B)$
- Exemplo:
  - Partícula com posição s e velocidade v
  - Velocidade *v* muda aleatoriamente (movimento browniano)
    - Posição s tem movimento mais suave  $(C_1)$
  - Apenas a posição s é medida

- Evolução no tempo
  - $X(t + \Delta t) = TX(t) + \mathcal{N}(0, A)$
- Observações
  - $Y(t) = PX(t) + \mathcal{N}(0, B)$
- Exemplo:
  - Partícula com posição s e velocidade v
  - Velocidade *v* muda aleatoriamente (movimento browniano)
    - Posição s tem movimento mais suave  $(C_1)$
  - Apenas a posição s é medida
  - Modelo resultante:

• 
$$X(t) = \begin{bmatrix} v(t) \\ s(t) \end{bmatrix}, T = \begin{bmatrix} 1 & 0 \\ \Delta t & 1 \end{bmatrix}, P = \begin{bmatrix} 0 & 1 \end{bmatrix}$$
  
•  $A = \begin{bmatrix} \sigma^2 \Delta t & \sigma^2 \Delta t^2/2 \\ \sigma^2 \Delta t^2/2 & \sigma^2 \Delta t^3/3 \end{bmatrix}$ 

### Inferência

- Estimativa da distribuição de X(t) é representada por uma média  $\mu$  (vetor) e variância  $\Sigma$  (matriz)
- Na passagem do tempo sem observações, a atualização a priori (ou predição) é trivial
  - $E[X(t + \Delta t)] = TE[X(t)]$
  - $Var[X(t + \Delta t)] = TVar[X(t)]T^T + A$
- Ao chegar uma nova observação Y(t), a atualização *a posteriori* é feita pela lei de Bayes assumindo distribuição gaussiana
  - $Var[X(t)|Y(t)]^{-1} = Var[X(t)]^{-1} + P^T B^{-1} P$
  - $E[X(t)|Y(t)] = Var[X(t)|Y(t)] \left( Var[X(t)]^{-1} E[X(t)] + P^T B^{-1} Y(t) \right)$

### Inferência

- Estimativa da distribuição de X(t) é representada por uma média  $\mu$  (vetor) e variância  $\Sigma$  (matriz)
- Na passagem do tempo sem observações, a atualização a priori (ou predição) é trivial
  - $E[X(t + \Delta t)] = TE[X(t)]$
  - $Var[X(t + \Delta t)] = TVar[X(t)]T^T + A$
- Ao chegar uma nova observação Y(t), a atualização *a posteriori* é feita pela lei de Bayes assumindo distribuição gaussiana
  - $Var[X(t)|Y(t)]^{-1} = Var[X(t)]^{-1} + P^T B^{-1} P$
  - $E[X(t)|Y(t)] = Var[X(t)|Y(t)] \left( Var[X(t)]^{-1} E[X(t)] + P^T B^{-1} Y(t) \right)$
- Contemple a dualidade entre esses dois tipos de eventos!
  - Um (*a priori*) atualiza a variância linearmente
  - O outro (a posteriori) atualiza a inversa linearmente

## Um parêntese

# Um parêntese

• Situação I (adição de erro):

$$X + Y, X \perp Y$$

$$E[X + Y] = E[X] + E[Y]$$

$$Var[X + Y] = Var[X] + Var[Y]$$

## Um parêntese

Situação I (adição de erro):

$$X + Y$$
,  $X \perp Y$   
 $E[X + Y] = E[X] + E[Y]$   
 $Var[X + Y] = Var[X] + Var[Y]$ 

• Situação II (adição de informação):

$$X = \mathcal{N}(z, \Sigma_X), \ Y = \mathcal{N}(z, \Sigma_Y), \ X \perp \!\!\!\perp Y$$

$$\widehat{z} = \arg\max_{z} P(X, Y; z)$$


$$\operatorname{Var}[\widehat{z}]^{-1} = \Sigma_X^{-1} + \Sigma_Y^{-1}$$

$$\operatorname{Var}[\widehat{z}]^{-1}\widehat{z} = \Sigma_X^{-1}X + \Sigma_Y^{-1}Y$$

- Na prática, observações podem chegar com atraso e fora de ordem
  - Atrasos de rede, processamento, etc.

- Na prática, observações podem chegar com atraso e fora de ordem
  - Atrasos de rede, processamento, etc.
- Questionamentos
  - É possível computar eventos de observação fora de ordem?
  - Se atrasos forem frequentes e substanciais, qual é a forma mais eficiente de manter (μ, Σ) atualizada?
  - Em caso de um atraso muito longo, é possível atualizar  $(\mu, \Sigma)$  sem ter que recalcular tudo?

- Na prática, observações podem chegar com atraso e fora de ordem
  - Atrasos de rede, processamento, etc.
- Questionamentos
  - É possível computar eventos de observação fora de ordem?
  - Se atrasos forem frequentes e substanciais, qual é a forma mais eficiente de manter (μ, Σ) atualizada?
  - Em caso de um atraso muito longo, é possível atualizar  $(\mu, \Sigma)$  sem ter que recalcular tudo?



### Meta-modelo

- Como modelar uma sequência de eventos de passagem do tempo e observação em uma única operação?
  - Passagem do tempo (a priori):

$$\Sigma_{\text{new}} = T\Sigma_{\text{old}}T^T + A$$

$$\mu_{\text{new}} = T\mu_{\text{old}}$$

• Observação (a posteriori):

$$\Sigma_{\text{new}}^{-1} = \Sigma_{\text{old}}^{-1} + P^T B^{-1} P$$

$$\mu_{\text{new}} = \Sigma_{\text{new}}(\Sigma_{\text{old}}^{-1} + P^T B^{-1} Y)$$

### Meta-modelo

- Como modelar uma sequência de eventos de passagem do tempo e observação em uma única operação?
  - Passagem do tempo (a priori):

$$\Sigma_{\text{new}} = T\Sigma_{\text{old}}T^T + A$$

$$\mu_{\text{new}} = T\mu_{\text{old}}$$

• Observação (a posteriori):

$$\Sigma_{\text{new}}^{-1} = \Sigma_{\text{old}}^{-1} + P^T B^{-1} P$$

$$\mu_{\text{new}} = \Sigma_{\text{new}}(\Sigma_{\text{old}}^{-1} + P^T B^{-1} Y)$$


 Vamos pegar emprestado um truque da área de processamento de imagens



# Coordenadas homogêneas

 Adicionar uma dimensão para permitir transformações projetivas (não-lineares)

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \simeq \begin{bmatrix} ax \\ ay \\ a \end{bmatrix} \quad (a \neq 0)$$



### A ideia

- Decompor  $\Sigma = U^{-1}V$  e só atualizar U ou V, conforme necessário
  - A redundância é intencional
- Semelhantemente, decompor  $\mu = U^{-1}z$

### A ideia

- Decompor  $\Sigma = U^{-1}V$  e só atualizar U ou V, conforme necessário
  - A redundância é intencional
- Semelhantemente, decompor  $\mu = U^{-1}z$
- Resultado: Os eventos viram multiplicações de matrizes
  - A priori:


$$\begin{bmatrix} U_{\text{new}} & V_{\text{new}} & z_{\text{new}} \end{bmatrix} = \begin{bmatrix} U_{\text{old}} & V_{\text{old}} & z_{\text{old}} \end{bmatrix} \begin{bmatrix} T^{-1} & T^{-1}A & 0 \\ 0 & T^{T} & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

• A posteriori:


$$\begin{bmatrix} U_{\text{new}} & V_{\text{new}} & z_{\text{new}} \end{bmatrix} = \begin{bmatrix} U_{\text{old}} & V_{\text{old}} & z_{\text{old}} \end{bmatrix} \begin{bmatrix} I & 0 & 0 \\ P^T B^{-1} P & I & P^T B^{-1} Y \\ 0 & 0 & 1 \end{bmatrix}$$



- Uma sequência de atualizações a priori e a posteriori é um produtório de matrizes
- Multiplicação de matrizes não é comutativa (a ordem importa!)
- Logo, não é possível manter essas atualizações em O(1)




- Uma sequência de atualizações a priori e a posteriori é um produtório de matrizes
- Multiplicação de matrizes não é comutativa (a ordem importa!)
- Logo, não é possível manter essas atualizações em O(1)




• No entanto, é possível atualizar em  $O(\log(n))$ . Como?

#### Usando uma árvore!



#### Usando uma árvore!



• Que tipo de árvore?

# Considerações

# Considerações

- Por que essa ideia não é usada na prática?
  - Alto custo de memória
  - Modelo precisa ser gaussiano e linear

# Considerações

- Por que essa ideia não é usada na prática?
  - Alto custo de memória
  - Modelo precisa ser gaussiano e linear
- Ideia não é inédita na literatura
  - Representações das atualizações do filtro de Kalman por meio de um "operador associativo" já foram propostas
  - Aplicações incluem paralelização do filtro de Kalman em GPU (ex.: Särkkä e García-Fernández, 2020)